electricity theft 2

May 1, 2023

1 Evaluación de algoritmos de Machine Learning supervisado en un conjunto de datos de fraude energético

1.0.1 Introducción

El presente proyecto busca clasificar, de forma efectiva, hogares que defraudan a la compañía eléctrica de los que no, evaluando el desempeño algoritmos de aprendizaje supervisado.

Para efecto, contamos con un conjunto de datos cuyas variables características son el consumo diario de energía eléctrica de 9957 hogares. La variable objetivo es de carácter binario, e indica cuáles hogares se detectaron como defraudadores (1) y cuáles no (0).

La selección de las métricas a utilizar dependerá de los objetivos específicos del proyecto y del equilibrio que se desee encontrar entre Precisión y Recall. Por ejemplo, si el costo de identificar un hogar que no defrauda a la compañía eléctrica como un hogar que sí defrauda es muy alto, entonces se debe priorizar Recall sobre Precision. Por otro lado, si el costo de identificar un hogar que defrauda a la compañía eléctrica como un hogar que no defrauda es muy alto, entonces se debe priorizar Precision sobre Recall.

Dado que el objetivo principal del proyecto es "optimizar las limitadas visitas comerciales a aquellos hogares que realmente son fraudulentos", hemos decidido que la métrica a tomar en cuenta para el objetivo de este proyecto será la **Precisión**. Sin embargo, también tomaremos en cuenta el Recall dentro de la obtención de métricas de los modelos evaluados.

A la par, para evaluar la capacidad de generalización de los modelos, revisaremos los valores de Error Cuadrado Medio (MSE) de cada uno. Calcularemos el MSE de validación cruzada así como el obtenido en los conjuntos de entrenamiento train_mse y evaluación test_mse. Cosideraremos los modelos con menor valor de train_mse - test_mse como aquellos con menor sobreajuste, es decir, mejor capacidad de generalización.

1.0.2 Etapa previa

```
[1]: # Importar librerías relevantes:
   import pandas as pd
   import numpy as np
   import matplotlib.pyplot as plt
   %matplotlib inline
   import seaborn as sns
   from sklearn.decomposition import PCA
   from sklearn.impute import SimpleImputer
```

```
from sklearn.metrics import recall_score, precision_score, make_scorer, mean_squared_error
from sklearn.model_selection import train_test_split, RandomizedSearchCV, mean_score
GridSearchCV, cross_val_score
from sklearn.ensemble import RandomForestClassifier, VotingClassifier, mean_selection
BaggingClassifier, GradientBoostingClassifier
from sklearn.linear_model import LogisticRegression
from sklearn.tree import DecisionTreeClassifier
from sklearn.neighbors import KNeighborsClassifier
from sklearn.svm import SVC
import xgboost as xgb
```

El conjunto de datos que utilizaremos fue obtenido en:

https://www.kaggle.com/datasets/avinemmatty/theft-data

```
[42]: electricity_data.describe()
```

```
[42]:
                 01-01-15
                              02-01-15
                                            03-01-15
                                                          04-01-15
                                                                        05-01-15
             8355.000000
                           8355.000000
                                         8355.000000
                                                      8356.000000
                                                                    8357.000000
      count
      mean
                 6.659159
                              6.700741
                                            6.846346
                                                          6.577144
                                                                        6.517476
      std
                11.668277
                             11.445378
                                           11.741275
                                                         11.837118
                                                                       11.996402
      min
             -104.550000
                            -50.773333
                                            0.000000
                                                          0.000000
                                                                        0.000000
      25%
                 0.500000
                              0.500000
                                            0.560000
                                                          0.580000
                                                                        0.600000
      50%
                 4.230000
                              4.290000
                                                          4.130000
                                                                        4.220000
                                            4.350000
      75%
                 9.200000
                              9.135000
                                            9.390000
                                                          8.800000
                                                                        8.670000
              312.090000
                            355.450000
                                          400.860000
                                                        332.160000
                                                                      363.620000
      max
                 06-01-15
                              07-01-15
                                            08-01-15
                                                          09-01-15
                                                                        10-01-15
             8358.000000
                           8360.000000
                                         8363.000000
                                                       8363.000000
                                                                     8363.000000
      count
      mean
                 6.431009
                              5.935722
                                            7.103165
                                                          6.580208
                                                                        6.761536
      std
               12.376089
                             53.196175
                                           53.057456
                                                         11.655925
                                                                       14.387630
                 0.000000 -4716.660000
      min
                                            0.000000
                                                          0.000000
                                                                        0.000000
      25%
                 0.550000
                              0.530000
                                            0.560000
                                                          0.575000
                                                                        0.570000
      50%
                 4.100000
                                                                        4.270000
                              4.150000
                                            4.060000
                                                          4.160000
      75%
                 8.510000
                              8.570000
                                            8.570000
                                                          8.815000
                                                                        9.130000
              406.850000
                            411.920000
                                         4720.090000
                                                        306.510000
                                                                     815.640000
      max
                 23-12-15
                              24-12-15
                                            25-12-15
                                                          26-12-15
                                                                        27-12-15
             9946.000000
                           9947.000000
                                         9946.000000
                                                       9947.000000
                                                                     9947.000000
      count
      mean
                 7.468988
                              6.655248
                                            6.743952
                                                          6.155237
                                                                        6.744348
      std
               29.455950
                             57.146371
                                           61.794120
                                                         89.771570
                                                                       86.381172
      min
            -1694.621500 -3738.970000 -3738.970000 -5608.423333 -5608.423333
      25%
                 0.750000
                              0.710000
                                            0.730000
                                                          0.705000
                                                                        0.695000
```

50%	4.550000	4.510000	4.610000	4.720000	4.860000	
75%	9.147500	9.070000	9.250000	9.570000	9.880000	
max	681.930000	661.300000	698.280000	762.980000	749.420000	
	28-12-15	29-12-15	30-12-15	31-12-15	CHK_STATE	
count	9947.000000	9950.000000	9950.000000	9955.000000	9956.000000	
mean	5.315301	5.560368	5.520999	5.517219	0.140016	
std	116.945584	127.731367	147.273463	187.331815	0.347021	
min	-5944.019000	-7112.985000	-10674.812500	-14236.640000	0.000000	
25%	0.695000	0.720000	0.690000	0.770000	0.000000	
50%	4.590000	4.670000	4.710000	4.760000	0.000000	
75%	9.280000	9.557500	9.520000	9.570000	0.000000	
max	766.080000	818.880000	767.330000	4367.701667	1.000000	

[8 rows x 366 columns]

Pretratamiento de datos Notamos que hay valores faltantes, por lo que imputaremos. Experimentamos con dos estrategias: SimpleImputer y KNNImputer. De forma general, la técnica de imputación simple de mediana entregó mejores resultados de clasificación que la imputación KNN.

```
[3]: # Crear un objeto SimpleImputer, ajustar y transformar el conjunto de datos imputer = SimpleImputer(strategy='median') electricity_data_imputed = pd.DataFrame(imputer.fit_transform(electricity_data), columns=electricity_data.columns)
```

[12]: electricity_data_imputed.describe()

[12]:		01-01-15	02-01-15	03-01-15	04-01-15	05-01-15	\	
	count	9957.000000	9957.000000	9957.000000	9957.000000	9957.000000		
	mean	6.268327	6.312873	6.444705	6.183664	6.148292		
	std	10.725577	10.521547	10.794284	10.880882	11.022599		
	min	-104.550000	-50.773333	0.000000	0.000000	0.000000		
	25%	1.050000	1.030000	1.150000	1.130000	1.170000		
	50%	4.230000	4.290000	4.350000	4.130000	4.220000		
	75%	8.130000	8.080000	8.260000	7.770000	7.650000		
	max	312.090000	355.450000	400.860000	332.160000	363.620000		
		06-01-15	07-01-15	08-01-15	09-01-15	10-01-15	•••	\
	count	9957.000000	9957.000000	9957.000000	9957.000000	9957.000000	•••	
	mean	6.056671	5.649311	6.615990	6.192761	6.362670	•••	
	std	11.371032	48.747727	48.637742	10.718973	13.217278	•••	
	min	0.000000	-4716.660000	0.000000	0.000000	0.000000	•••	
	25%	1.100000	1.090000	1.070000	1.080000	1.120000	•••	
	50%	4.100000	4.150000	4.060000	4.160000	4.270000	•••	
	75%	7.520000	7.580000	7.540000	7.730000	8.010000	•••	
	max	406.850000	411.920000	4720.090000	306.510000	815.640000	•••	

```
24-12-15
                        25-12-15
                                      26-12-15
                                                    27-12-15
                                                                  28-12-15
       9957.000000
                     9957.000000
                                   9957.000000
                                                 9957.000000
                                                               9957.000000
count
mean
           6.653093
                        6.741594
                                      6.153796
                                                    6.742456
                                                                  5.314572
         57.117705
                       61.760014
                                     89.726486
                                                   86.337800
                                                                116.886840
std
      -3738.970000
                    -3738.970000 -5608.423333 -5608.423333 -5944.019000
min
25%
           0.710000
                        0.730000
                                      0.710000
                                                    0.700000
                                                                  0.700000
50%
          4.510000
                        4.610000
                                      4.720000
                                                    4.860000
                                                                  4.590000
75%
           9.060000
                        9.250000
                                      9.570000
                                                    9.870000
                                                                  9.270000
        661.300000
                      698.280000
                                    762.980000
                                                  749.420000
                                                                766.080000
max
           29-12-15
                         30-12-15
                                        31-12-15
                                                     CHK STATE
                                                                \
       9957.000000
                      9957.000000
                                     9957.000000
                                                   9957.000000
count
           5.559742
                         5.520428
                                        5.517067
                                                      0.140002
mean
std
        127.686458
                       147.221682
                                      187.312999
                                                      0.347007
      -7112.985000 -10674.812500 -14236.640000
                                                      0.000000
min
25%
           0.720000
                         0.700000
                                        0.770000
                                                      0.000000
50%
           4.670000
                         4.710000
                                        4.760000
                                                      0.000000
75%
           9.550000
                         9.510000
                                        9.570000
                                                      0.000000
        818.880000
                       767.330000
                                     4367.701667
                                                      1.000000
max
       mean_daily_consumption
                   9957.000000
count
                     24.044582
mean
std
                     12.670696
min
                   -130.317041
25%
                     19.301945
50%
                     22.326356
75%
                     26.011260
max
                    308.545918
```

[8 rows x 367 columns]

Algo curioso de este conjunto de datos es que la presencia de valores negativos, lo cual en primera instancia parecería extraño si se trata de consumo energía. Sin embargo, decidimos dejar estos valores porque pueden formar parte del fraude de robo de energía: los valores negativos pueden ocurrir si los medidores de los hogares defraudadores están trucados.

```
[4]: # Obtener las variables características (X) y variable objetivo (y):

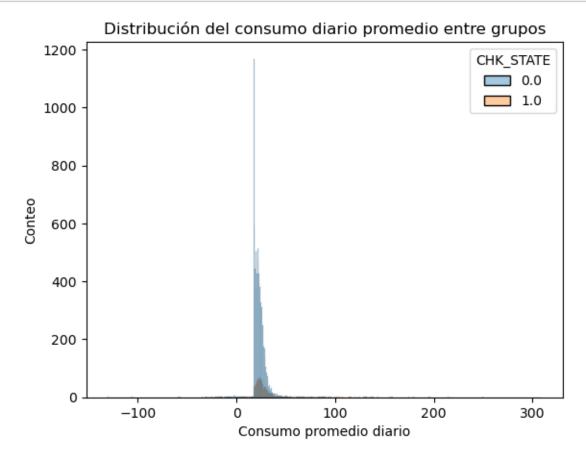
X = electricity_data_imputed.drop('CHK_STATE', axis=1)
y= electricity_data_imputed['CHK_STATE']

# Dividir el dataset en subconjuntos de entrenamiento y evaluación:

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=.3, □
→random_state=123)
```

Análisis Exploratorio de datos Con el EDA, queremos responder la pregunta: qué hogares consumen más energía: los "defraudadores" o los que no lo son? De exisitir una diferencia, es esta estadísticamente significativa?

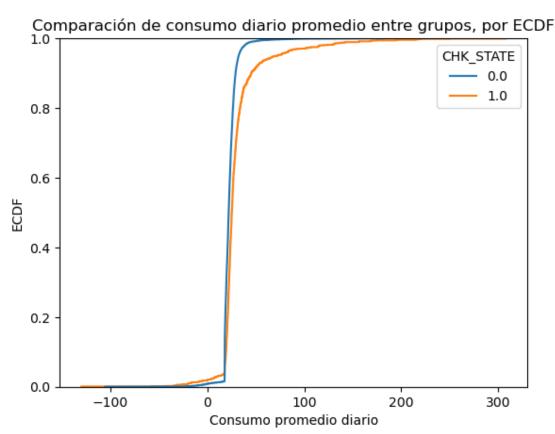
Primero, graficamos la distribución del consumo medio por clases:



Con la excepción de notar el claro desbalance entre clases, debido a la distribución de los datos resulta muy difícil observar diferencias entre clases en el histograma.

En este caso, resultaría mejor observar y comparar la función de distribución acumulada empírica por clase (ECDF):

```
[11]: # Graficar ECDF:
```



La gráfica de función de distribución acumulada empírica indica que los hogares identificados como "defraudadores" ('CHK_STATE'==1) consumen mayor cantidad de energía que la contraparte.

Para saber si esta diferencia es significativa y no producto del azar, realizamos una prueba de diferencia de medias:

```
t, p = ttest_ind(chk_state_0_consumption, chk_state_1_consumption)
print("t-value:", t)
print("p-value:", p)
```

t-value: -22.398141706205777 p-value: 1.9048866582063408e-108

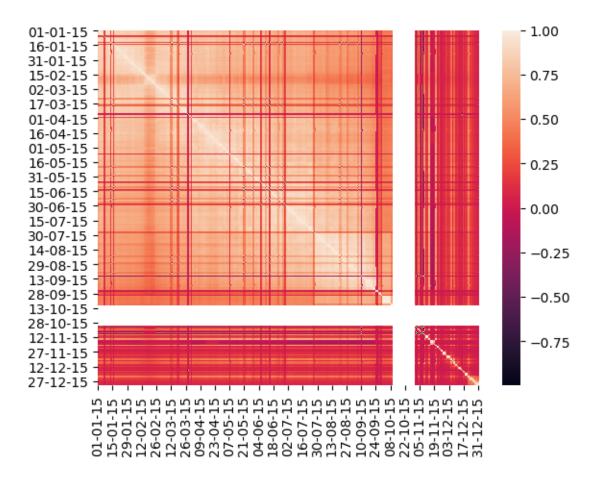
 $\mathbf{H0:}\ \mathbf{1} = \mathbf{2}$ La hipótesis nula (H0) en la prueba t de dos muestras es que las medias poblacionales de dos muestras independientes son iguales.

Conclusión: La prueba de medias indica que hay una diferencia significativa en el consumo diario promedio entre los dos grupos. El valor-p nos fuerza a rechazar H0 e indica que es extremadamente probable que esta diferencia sea real y no resultado del azar.

Ahora, revisaremos la correlación entre las variables características en un mapa de calor:

```
[26]: # Graficar mapa de calor de las correlaciones entre variables características: sns.heatmap(X.corr())
```

[26]: <AxesSubplot:>



Dado el predominio de los colores claros en la gráfica, concluimos que existe mucha correlación entre las variables características. Esto tiene sentido, porque recordemos que cada una es el consumo de energía de los hogares para cada día de 2015.

Esto nos lleva a la conclusión de que tal vez sería prudente aplicar en los datos la técnica de aprendizaje no supervisado "Análisis de Componentes Principales". Una de las muchas ventajas de esta técnica es que elimina todo rastro de correlación entre variables, lo cual incluye potenciales problemas de multicolinealidad.

Escalado / Normalizado de datos Para el entrenamiento de los modelos, parte integral de la estrategia es el escalado o la normalización de datos. Más adelante, evaluaremos ambos para ver cuál nos entrega mejores métricas.

Análisis de Componentes Principales Previamente, habíamos notado alta correlación entre las variables características. Por tanto, implementaremos PCA en la estrategia y revisaremos si esta técnica mejora el desempeño de los modelos.

```
[6]: # PCA para datos escalados:
    pca = PCA()
    X_scaled_pca = pca.fit_transform(X_scaled)
    exp_variance = pca.explained_variance_ratio_

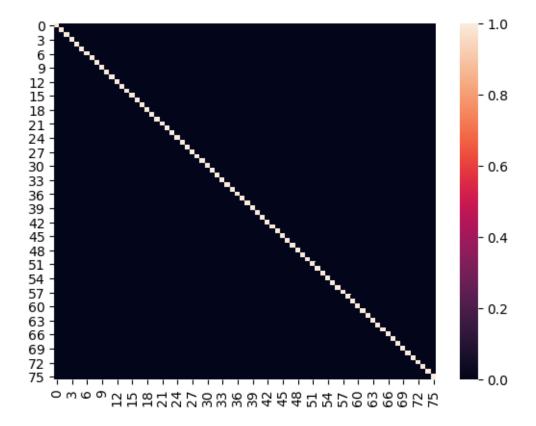
# Número mínimo de componentes principales que acumulan al menos el XX% de_
    varianza:
    requested_variance = 0.975
    exp_variance_cum_sum = np.cumsum(exp_variance)
    n_components = np.where(exp_variance_cum_sum >= requested_variance)[0][0] + 1
    print(f"Núm. de componentes principales con {requested_variance*100}% de_
    varianza: ", n_components)

X_scaled_pca = X_scaled_pca[:, :n_components]
```

Núm. de componentes principales con 97.5% de varianza: 84 (9957, 84)

[31]: # Revisar correlación de datos escalados con PCA:
sns.heatmap(pd.DataFrame(X_scaled_pca).corr())

[31]: <AxesSubplot:>



```
[10]: # PCA para datos normalizados:

pca = PCA()

X_norm_pca = pca.fit_transform(X_norm)

exp_variance = pca.explained_variance_ratio_

# Número mínimo de componentes principales que acumulan al menos el XX% de∟

→varianza:
```

Núm. de componentes principales con 97.5% de varianza: 77 (9957, 77)

Remuestro (resultados) Aunque hemos omitido el código en este notebook, reportamos que como parte de la experimentación hemos efectuado remuestreo de la clase subrepresentada, es decir, de aquellos hogares en el dataset etiquetados como "defraudadores" CHK_STATE==1. Originalmente, el dataset tiene una proporción de alrededor 1:7 en la relación de hogares etiquetados como "defraudadores" versus "no defraudadores", respectivamente. Se ha inspeccionado el desempeño del algoritmo Regresión Logística en términos de recall y precisión, con proporiciones desde 1:7 hasta 1:3.

Conclusión: La técnica de sobremuestreo de la clase minoritaria no es necesaria ni conveniente para este dataset específico. Las razones son:

- 1) El sobremuestro de la clase minoritaria (1) no solo que no mejoró, sino que empeoró las métricas de precisión y clasificación, como se observa en el gráfico abajo.
- 2) Tanto recall como precisión ponderados, especificadas en los modelos a continuación, toman en consideración el desbalance de clases.
- 3) El remuestreo extremo de una de las clases no es una técnica apropiada pues la muestra dejaría de representar a la población original.

```
[13]: # Observar el efecto del remuestro de la clase minoritaria en Precision y

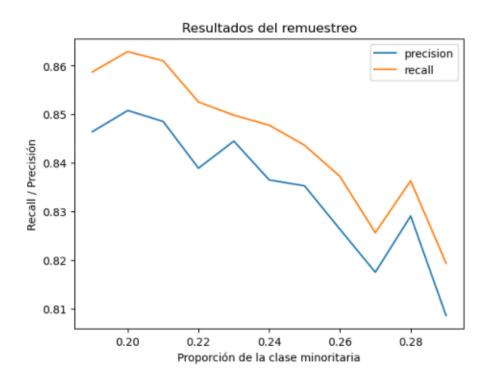
→Recall:

img = plt.imread('resample_results.png')

plt.axis('off')

plt.imshow(img)
```

[13]: <matplotlib.image.AxesImage at 0x22907d92250>



1.0.3 Entrenamiento y evaluación de modelos clasificadores

El primer paso es crear una función que, en pocas líneas de código, obtenga Recall, Precisión y MSE de cada algoritmo implementado con scikit-learn.

```
y_pred_test = model_instance.predict(X_test)
         # Calcular el MSE de los datos de entrenamiento y evaluación:
         train_mse = mean_squared_error(y_train, y_pred_train)
         test_mse = mean_squared_error(y_test, y_pred_test)
         return {'recall':recall, 'precision':precision, 'cv_mse':cv_mse,
                 'train_mse':train_mse, 'test_mse':test_mse}
[9]: # Crear instancias de algoritmos clasificadores a comparar:
     lr = LogisticRegression(solver='newton-cg')
     knn = KNeighborsClassifier()
     dtc = DecisionTreeClassifier(random_state=123)
     rfc = RandomForestClassifier(random_state=123)
     gbc = GradientBoostingClassifier(random_state=123)
     svc = SVC(random_state=123)
     xgbc = xgb.XGBClassifier(objective='binary:logistic', n_estimators=10, seed=123)
     classifiers = {'lr':lr, 'knn':knn, 'dtc':dtc, 'rfc':rfc, 'gbc': gbc, 'svc':svc, |
      [35]: # Ajustar modelos utilizando la fórmula personalizada get model metrics() sobre
      ⇔los datos crudos:
     clf_adj = {}
     for clf_name, clf in classifiers.items():
         clf_adj[clf_name] = get_model_metrics(clf, X_train, X_test, y_train,_u
      →y_test).values()
     clf df = pd.DataFrame(clf adj,
                          index=['recall', 'precision', 'cv_mse', 'train_mse', |
      clf_df
[35]:
             recall precision cv_mse train_mse test_mse
           0.875167 0.854037 0.134022
                                         0.102884 0.124833
     lr
           0.859103 0.832304 0.136462
                                         0.089109 0.140897
     knn
     dtc
           0.819612 0.821950 0.185105
                                         0.002009 0.180388
           0.002009 0.120147
     rfc
     gbc
           0.875837 0.854917 0.119816
                                         0.081073 0.124163
           0.868809
                     0.867812 0.134453
                                         0.132157 0.131191
     svc
     xgbc 0.871486
                     0.847458 0.123834
                                         0.063567 0.128514
[19]: clf_df.mean() # Imputación de la mediana
[19]: recall
                 0.878179
     precision
                 0.868320
```

```
0.063916
     train_mse
     test_mse
                  0.121821
     dtype: float64
[10]: # Ajustar modelos utilizando la fórmula personalizada get_model_metrics() sobreu
      ⇔los datos escalados con PCA:
     clf_adj_scaled_pca = {}
     for clf_name, clf in classifiers.items():
         clf_adj_scaled_pca[clf_name] = get_model_metrics(clf, X_train_scaled_pca,
                                                        X_test_scaled_pca,_

y_train, y_test).values()
     clf_df_scaled_pca = pd.DataFrame(clf_adj_scaled_pca,
                           index=['recall', 'precision', 'cv_mse', 'train_mse', |
      clf_df_scaled_pca
[10]:
             recall precision
                                 cv_mse train_mse test_mse
     lr
           0.883199
                    0.877931 0.118382
                                          0.113359 0.116801
           0.889893
                     0.878712 0.107046
                                          0.087961 0.110107
     knn
           0.827979 0.826943 0.170612
     dtc
                                          0.002009 0.172021
     rfc
           0.893909 0.882532 0.109484
                                          0.002009 0.106091
     gbc
           0.891232
                     0.878396 0.104463
                                          0.071746 0.108768
           0.886546
                     0.879811 0.115225
                                          0.104032 0.113454
     SVC
     xgbc 0.892570
                     0.880562 0.108481
                                          0.056823 0.107430
[11]: clf_df_scaled_pca.mean()
[11]: recall
                  0.880761
                  0.872127
     precision
     cv mse
                  0.119099
     train_mse
                  0.062563
     test_mse
                  0.119239
     dtype: float64
[39]: # Ajustar modelos utilizando la fórmula personalizada get_model_metrics() sobre
      ⇔los datos normalizados con PCA:
     clf adj norm pca = {}
     for clf_name, clf in classifiers.items():
         clf_adj_norm_pca[clf_name] = get_model_metrics(clf, X_train_norm_pca,
                                                        X_test_norm_pca, y_train,_
      →y_test).values()
     clf_df_norm_pca = pd.DataFrame(clf_adj_norm_pca,
```

0.118607

cv_mse

```
[39]:
             recall
                     precision
                                           train_mse
                                                      test_mse
                                   cv_mse
            0.870817
                       0.854572
                                0.130722
      lr
                                            0.129717
                                                      0.129183
     knn
            0.865462
                       0.840198
                                0.131296
                                            0.086239
                                                      0.134538
                                0.182381
      dtc
            0.826640
                       0.829408
                                            0.002009
                                                      0.173360
      rfc
            0.886212
                       0.872412
                                0.119242
                                            0.002152
                                                      0.113788
      gbc
           0.885542
                       0.870336
                                0.116515
                                            0.075764
                                                      0.114458
                                 0.123691
                                                      0.120147
      svc
            0.879853
                       0.868131
                                            0.110633
      xgbc 0.877510
                       0.857827
                                0.121251
                                            0.061989
                                                      0.122490
```

```
[23]: clf_df_norm_pca.mean()
```

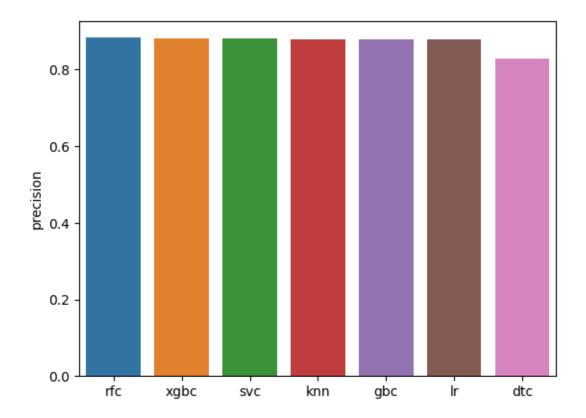
```
[23]: recall 0.877988
precision 0.868615
cv_mse 0.119714
train_mse 0.060533
test_mse 0.122012
```

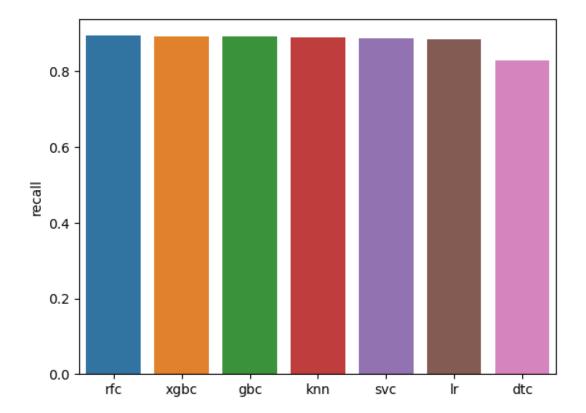
dtype: float64

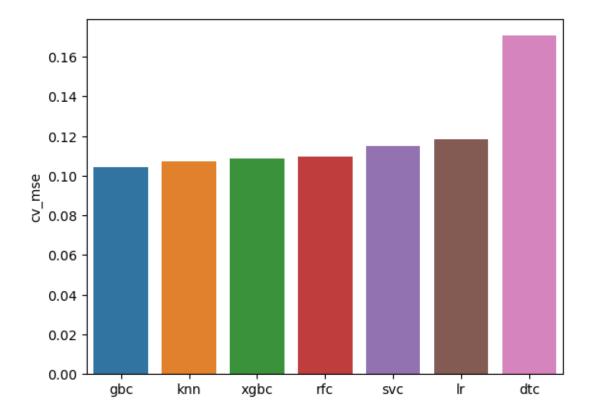
En general, el desempeño de los modelos, tanto en términos de desempeño del recall como de la precisión, es ligeramente mejor para los datos escalados y con PCA, en comparación con las otras dos aproximaciones.

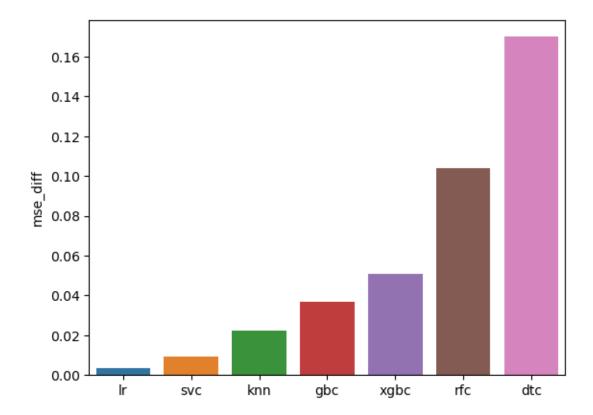
Ranking del desempeño individual de los modelos, con datos escalados y con PCA

```
[13]: # Ranqueo de la precisión, de mejor a peor:
sorted_index = clf_df_scaled_pca['precision'].sort_values(ascending=False).index
sns.barplot(x=clf_df_scaled_pca.index, y='precision', data=clf_df_scaled_pca,__
order=sorted_index)
plt.show()
```









Conclusión: Los resultados obtenidos con el RandomForestClassifier indican que este algoritmo tiene el mejor desempeño en la tarea de clasificación para este conjunto de datos en específico. En el otro extremo, el clasificador de árboles de decisión es el de peor desempeño en todos los aspectos.

Aunque el RandomForestClassifier tuvo el mejor desempeño clasificador en términos de Precisión y también Recall, es necesario considerar que también es el segundo con mayor sobreajuste. Es importante tener en cuenta que los resultados de la validación cruzada y la evaluación del conjunto de prueba deben interpretarse en conjunto para evaluar la calidad del modelo. En general, se busca un modelo que tenga un bajo error de generalización y que no sobreajuste a los datos de entrenamiento.

Dado que los resultados obtenidos con el RandomForestClassifier son los más prometedores, trataremos de reducir el sobreajuste del modelo dsin afectar su capacidad clasificadora. Esto lo haremos mediante optimización de hiperparámetros.

Ajuste de hiperparámetros para clasificador Random Forest

```
'min_samples_leaf': [1, 2, 4], # Pred. 1
                    'max_features': ['sqrt', 'log2'] # Pred. auto
                   }
      # Definir el objeto scorer personalizado para el recall
      scoring = make_scorer(recall_score, average='weighted')
      # Definir el objeto GridSearchCV y ajustar el modelo
      grid_search = GridSearchCV(rf_grid, param_grid, cv=5, scoring=scoring,_u
       \rightarrown jobs=-1)
      grid_search.fit(X_train_scaled_pca, y_train)
      # Mejores hiperparámetros:
      rf_best_params = grid_search.best_params_
      # Imprimir los mejores hiperparámetros y la precisión promedio en la validación
       \hookrightarrow cruzada
      print("Mejores hiperparámetros:", rf_best_params)
      print("Recall promedio en la validación cruzada:", grid_search.best_score_)
      # Mejores hiperparámetros: {'max_depth': None, 'max_features': 'auto',_
       → 'min_samples_leaf': 1,
      #'min samples split': 5, 'n estimators': 150}
      # Recall promedio en la validación cruzada: 0.902282060023421
     Mejores hiperparámetros: {'max_depth': None, 'max_features': 'sqrt',
     'min_samples_leaf': 2, 'min_samples_split': 2, 'n_estimators': 150}
     Recall promedio en la validación cruzada: 0.8938152537642094
[17]: # Ajustar el modelo de RandomForestClassifier con los hiperparámetros obtenidos
       ⇔para revisar sus métricas.
      rfc_grid_params = RandomForestClassifier(
          n estimators= 150,
          max_depth= None,
          min samples split= 2,
          min_samples_leaf= 2,
          max_features= 'sqrt',
          random_state=123)
      # Obtener métricas del modelo resultante de GridSearchCV:
      rfc_grid_metrics = get_model_metrics(rfc_grid_params, X_train_scaled_pca,
                                           X_test_scaled_pca, y_train, y_test)
      rfc_grid_metrics
[17]: {'recall': 0.891566265060241,
       'precision': 0.8792472099595813,
```

```
'cv_mse': 0.10618474623579055,
'train_mse': 0.010331467929401636,
'test_mse': 0.10843373493975904}
```

En el modelo ajustado con los mejores hiperparámetros, seleccionados con GridSearchCV, aún observamos sobreajuste, ya que train_mse > test_mse. Por este motivo, decidimos hacer una selección manual sobre los hiperparámetros ya escogidos.

```
[18]: {'recall': 0.8835341365461847,
    'precision': 0.880611918757581,
    'cv_mse': 0.11823845606388161,
    'train_mse': 0.0984359305495767,
    'test mse': 0.11646586345381527}
```

Conclusión Con la selección manual basada en los resultados de GridSearchCV, las métricas de generalización mejoraron sustancialmente. Por su parte, la Precisión mejoró modestamente. Hemos logrado un modelo de RandomForestClassifier equilibrado con un desempeño superior a los previamente vistos.

1.0.4 Experimentación con algoritmos de ensamble

El objuetivo de este apartado es determinar si podemos alcanzar mejores modelos que el logrado con RandomForestClassifier con modelos de ensamble. Para esto, hemos seleccionado dos modelos de ensamble: VotingClassifier y BaggingClassifier.

VotingClassifier es un estimador que combina múltiples clasificadores para realizar una predicción final mediante votación. Es decir, cada clasificador proporciona su predicción y se elige la clase más votada como la predicción final del modelo. Para el modelo creado con VotingClassifier, incluiremos todos los algoritmos revisados previamente, incluyendo RandomForestClassifier con parámetros optimizados.

Por su parte, BaggingClassifier utiliza el método de Bootstrap Aggregating para mejorar la precisión de los modelos de aprendizaje automático. El modelo crea múltiples conjuntos de datos de entrenamiento a partir del conjunto de datos original mediante muestreo aleatorio con reemplazo, y entrena un clasificador diferente en cada uno de estos conjuntos. Luego, las predicciones de cada

clasificador se combinan mediante votación o promedio para producir una predicción final. En este caso, tomaremos el modelo de RandomForestClassifier optimizado como estimador base.

VotingClassifier

```
[19]: # Crear instancias de algoritmos clasificadores a comparar:
      lr = LogisticRegression(solver='newton-cg')
      knn = KNeighborsClassifier(n neighbors=3)
      dtc = DecisionTreeClassifier(random state=123)
      rfc = rfc tuned params = RandomForestClassifier(
          n_estimators= 300,
          max_depth= 5,
          min_samples_split= 2,
          min_samples_leaf= 1,
          max_features= 'sqrt',
          random_state=123)
      gbc = GradientBoostingClassifier(random_state=123)
      svc = SVC(random_state=123)
      xgbc = xgb.XGBClassifier(objective='binary:logistic', n_estimators=10, seed=123)
      classifiers = [('lr', lr), ('knn', knn), ('dtc', dtc), ('rfc', rfc),
                     ('gbc', gbc), ('svc', svc), ('xgbc', xgbc)]
```

BaggingClassifier

1.0.5 Experimentación con Redes Neuronales Artificiales

Antes de comparar el desempeño de los modelos de ensamble con el de RandomForestClassifier optimizado, decidimos experimentar un poco con redes neuronales. Crearemos dos modelos: una red neuronal secuencial densa (DNN) y uno de mayor complejidad, una red neuronal convolucional unidimensional (CNN).

Red neuronal secuencial densa (DNN)

```
[22]: from keras.models import Sequential from keras.layers import Dense, Dropout from keras.metrics import Recall, Precision
```

```
0.1206 - recall: 0.1537 - precision: 0.6436 - val_loss: 0.4132 - val_mse: 0.1172
- val_recall: 0.1958 - val_precision: 0.5873
Epoch 3/100
0.1116 - recall: 0.1703 - precision: 0.6442 - val_loss: 0.3912 - val_mse: 0.1093
- val_recall: 0.1905 - val_precision: 0.6316
Epoch 4/100
0.1052 - recall: 0.1842 - precision: 0.7474 - val_loss: 0.3753 - val_mse: 0.1039
- val_recall: 0.1587 - val_precision: 0.6522
Epoch 5/100
0.1010 - recall: 0.1944 - precision: 0.7612 - val_loss: 0.3656 - val_mse: 0.1016
- val_recall: 0.1693 - val_precision: 0.6809
Epoch 6/100
0.0961 - recall: 0.2046 - precision: 0.8050 - val_loss: 0.3623 - val_mse: 0.1000
- val_recall: 0.1799 - val_precision: 0.6538
Epoch 7/100
0.0951 - recall: 0.2274 - precision: 0.8027 - val_loss: 0.3572 - val_mse: 0.0988
- val_recall: 0.1852 - val_precision: 0.6250
Epoch 8/100
0.0946 - recall: 0.2325 - precision: 0.7991 - val_loss: 0.3492 - val_mse: 0.0972
- val_recall: 0.1958 - val_precision: 0.6981
Epoch 9/100
0.0924 - recall: 0.2376 - precision: 0.7924 - val_loss: 0.3432 - val_mse: 0.0957
- val_recall: 0.1958 - val_precision: 0.6852
Epoch 10/100
0.0923 - recall: 0.2389 - precision: 0.7866 - val_loss: 0.3378 - val_mse: 0.0938
- val recall: 0.2169 - val precision: 0.7069
Epoch 11/100
0.0907 - recall: 0.2440 - precision: 0.7837 - val_loss: 0.3349 - val_mse: 0.0931
- val_recall: 0.1958 - val_precision: 0.7115
Epoch 12/100
0.0900 - recall: 0.2490 - precision: 0.8000 - val_loss: 0.3367 - val_mse: 0.0926
- val_recall: 0.2381 - val_precision: 0.6716
Epoch 13/100
0.0896 - recall: 0.2592 - precision: 0.7786 - val_loss: 0.3320 - val_mse: 0.0923
- val_recall: 0.2063 - val_precision: 0.6964
Epoch 14/100
```

```
0.0892 - recall: 0.2541 - precision: 0.8230 - val_loss: 0.3309 - val_mse: 0.0904
- val_recall: 0.2540 - val_precision: 0.6957
Epoch 15/100
0.0881 - recall: 0.2618 - precision: 0.7954 - val_loss: 0.3309 - val_mse: 0.0909
- val_recall: 0.2540 - val_precision: 0.7059
Epoch 16/100
0.0871 - recall: 0.2922 - precision: 0.7877 - val_loss: 0.3347 - val_mse: 0.0911
- val_recall: 0.2487 - val_precision: 0.6812
Epoch 17/100
0.0866 - recall: 0.2897 - precision: 0.8028 - val_loss: 0.3311 - val_mse: 0.0897
- val_recall: 0.2804 - val_precision: 0.6795
Epoch 18/100
0.0856 - recall: 0.2948 - precision: 0.7973 - val_loss: 0.3298 - val_mse: 0.0895
- val_recall: 0.2804 - val_precision: 0.6795
Epoch 19/100
0.0852 - recall: 0.3215 - precision: 0.8161 - val_loss: 0.3280 - val_mse: 0.0886
- val_recall: 0.2910 - val_precision: 0.6962
Epoch 20/100
0.0847 - recall: 0.3240 - precision: 0.7681 - val_loss: 0.3219 - val_mse: 0.0879
- val_recall: 0.2857 - val_precision: 0.7200
Epoch 21/100
0.0853 - recall: 0.3126 - precision: 0.8013 - val_loss: 0.3227 - val_mse: 0.0872
- val_recall: 0.3016 - val_precision: 0.6706
Epoch 22/100
0.0825 - recall: 0.3342 - precision: 0.8018 - val_loss: 0.3289 - val_mse: 0.0878
- val recall: 0.3069 - val precision: 0.7073
Epoch 23/100
0.0840 - recall: 0.3380 - precision: 0.7917 - val_loss: 0.3260 - val_mse: 0.0863
- val_recall: 0.3333 - val_precision: 0.7079
Epoch 24/100
0.0833 - recall: 0.3253 - precision: 0.7853 - val_loss: 0.3272 - val_mse: 0.0858
- val_recall: 0.3651 - val_precision: 0.6970
Epoch 25/100
0.0819 - recall: 0.3558 - precision: 0.8000 - val_loss: 0.3271 - val_mse: 0.0858
- val_recall: 0.3439 - val_precision: 0.6915
Epoch 26/100
```

```
0.0817 - recall: 0.3545 - precision: 0.7837 - val_loss: 0.3225 - val_mse: 0.0850
- val_recall: 0.3492 - val_precision: 0.7174
Epoch 27/100
0.0810 - recall: 0.3647 - precision: 0.7994 - val_loss: 0.3246 - val_mse: 0.0851
- val_recall: 0.3439 - val_precision: 0.7065
Epoch 28/100
0.0817 - recall: 0.3837 - precision: 0.7704 - val_loss: 0.3231 - val_mse: 0.0852
- val_recall: 0.3545 - val_precision: 0.6979
Epoch 29/100
0.0811 - recall: 0.3825 - precision: 0.7778 - val_loss: 0.3187 - val_mse: 0.0843
- val_recall: 0.3492 - val_precision: 0.6875
Epoch 30/100
0.0806 - recall: 0.3850 - precision: 0.7652 - val_loss: 0.3198 - val_mse: 0.0841
- val_recall: 0.3651 - val_precision: 0.6765
Epoch 31/100
0.0806 - recall: 0.3939 - precision: 0.7711 - val_loss: 0.3188 - val_mse: 0.0844
- val_recall: 0.3333 - val_precision: 0.7159
Epoch 32/100
0.0805 - recall: 0.3672 - precision: 0.7707 - val_loss: 0.3217 - val_mse: 0.0843
- val_recall: 0.3598 - val_precision: 0.7158
Epoch 33/100
0.0804 - recall: 0.3926 - precision: 0.7725 - val_loss: 0.3200 - val_mse: 0.0836
- val_recall: 0.3968 - val_precision: 0.7143
Epoch 34/100
0.0792 - recall: 0.4028 - precision: 0.7866 - val_loss: 0.3226 - val_mse: 0.0840
- val recall: 0.3704 - val precision: 0.7071
Epoch 35/100
0.0800 - recall: 0.3748 - precision: 0.7763 - val_loss: 0.3229 - val_mse: 0.0838
- val_recall: 0.3968 - val_precision: 0.7009
Epoch 36/100
0.0785 - recall: 0.4142 - precision: 0.7780 - val_loss: 0.3249 - val_mse: 0.0841
- val_recall: 0.3968 - val_precision: 0.7009
Epoch 37/100
0.0793 - recall: 0.3914 - precision: 0.7797 - val_loss: 0.3248 - val_mse: 0.0840
- val_recall: 0.3704 - val_precision: 0.6931
Epoch 38/100
```

```
0.0776 - recall: 0.4168 - precision: 0.8059 - val_loss: 0.3276 - val_mse: 0.0849
- val_recall: 0.3915 - val_precision: 0.7048
Epoch 39/100
0.0784 - recall: 0.4130 - precision: 0.7812 - val_loss: 0.3246 - val_mse: 0.0834
- val_recall: 0.3915 - val_precision: 0.6727
Epoch 40/100
0.0785 - recall: 0.4193 - precision: 0.7728 - val_loss: 0.3273 - val_mse: 0.0836
- val_recall: 0.3968 - val_precision: 0.6881
Epoch 41/100
0.0786 - recall: 0.4155 - precision: 0.7730 - val_loss: 0.3251 - val_mse: 0.0834
- val_recall: 0.3915 - val_precision: 0.6852
Epoch 42/100
0.0774 - recall: 0.4168 - precision: 0.7646 - val_loss: 0.3219 - val_mse: 0.0838
- val_recall: 0.3810 - val_precision: 0.6923
Epoch 43/100
0.0781 - recall: 0.4117 - precision: 0.7807 - val_loss: 0.3243 - val_mse: 0.0835
- val_recall: 0.3862 - val_precision: 0.6887
Epoch 44/100
0.0772 - recall: 0.4231 - precision: 0.7726 - val_loss: 0.3236 - val_mse: 0.0834
- val_recall: 0.4074 - val_precision: 0.6875
Epoch 45/100
0.0773 - recall: 0.4193 - precision: 0.7914 - val_loss: 0.3242 - val_mse: 0.0828
- val_recall: 0.4233 - val_precision: 0.6723
Epoch 46/100
0.0765 - recall: 0.4269 - precision: 0.7832 - val_loss: 0.3273 - val_mse: 0.0832
- val recall: 0.4127 - val precision: 0.6610
Epoch 47/100
0.0754 - recall: 0.4435 - precision: 0.7896 - val_loss: 0.3274 - val_mse: 0.0835
- val_recall: 0.3862 - val_precision: 0.6822
Epoch 48/100
0.0754 - recall: 0.4371 - precision: 0.7945 - val_loss: 0.3263 - val_mse: 0.0835
- val_recall: 0.4074 - val_precision: 0.6754
Epoch 49/100
0.0764 - recall: 0.4460 - precision: 0.7614 - val_loss: 0.3268 - val_mse: 0.0837
- val_recall: 0.3968 - val_precision: 0.6696
Epoch 50/100
```

```
0.0754 - recall: 0.4371 - precision: 0.7908 - val_loss: 0.3254 - val_mse: 0.0826
- val_recall: 0.4074 - val_precision: 0.6754
Epoch 51/100
0.0756 - recall: 0.4536 - precision: 0.7778 - val_loss: 0.3246 - val_mse: 0.0829
- val_recall: 0.3915 - val_precision: 0.6727
Epoch 52/100
0.0757 - recall: 0.4536 - precision: 0.7677 - val_loss: 0.3301 - val_mse: 0.0829
- val_recall: 0.4392 - val_precision: 0.6803
Epoch 53/100
0.0747 - recall: 0.4612 - precision: 0.7756 - val_loss: 0.3254 - val_mse: 0.0815
- val_recall: 0.4444 - val_precision: 0.6667
Epoch 54/100
0.0747 - recall: 0.4600 - precision: 0.7904 - val_loss: 0.3248 - val_mse: 0.0823
- val_recall: 0.4127 - val_precision: 0.6783
Epoch 55/100
0.0744 - recall: 0.4498 - precision: 0.7763 - val_loss: 0.3223 - val_mse: 0.0821
- val_recall: 0.4127 - val_precision: 0.6610
Epoch 56/100
0.0743 - recall: 0.4549 - precision: 0.7885 - val_loss: 0.3227 - val_mse: 0.0827
- val_recall: 0.3915 - val_precision: 0.6789
Epoch 57/100
0.0738 - recall: 0.4587 - precision: 0.7899 - val_loss: 0.3258 - val_mse: 0.0826
- val_recall: 0.4127 - val_precision: 0.6610
Epoch 58/100
0.0747 - recall: 0.4473 - precision: 0.7788 - val_loss: 0.3285 - val_mse: 0.0828
- val recall: 0.4550 - val precision: 0.6825
Epoch 59/100
0.0731 - recall: 0.4740 - precision: 0.7707 - val_loss: 0.3251 - val_mse: 0.0823
- val_recall: 0.4392 - val_precision: 0.6803
Epoch 60/100
0.0738 - recall: 0.4701 - precision: 0.7822 - val_loss: 0.3277 - val_mse: 0.0829
- val_recall: 0.4339 - val_precision: 0.6833
Epoch 61/100
0.0737 - recall: 0.4676 - precision: 0.7846 - val_loss: 0.3250 - val_mse: 0.0822
- val_recall: 0.4180 - val_precision: 0.6752
Epoch 62/100
```

```
0.0738 - recall: 0.4651 - precision: 0.7905 - val_loss: 0.3255 - val_mse: 0.0819
- val_recall: 0.4339 - val_precision: 0.6833
Epoch 63/100
0.0737 - recall: 0.4714 - precision: 0.7811 - val_loss: 0.3281 - val_mse: 0.0822
- val_recall: 0.4339 - val_precision: 0.6721
Epoch 64/100
0.0735 - recall: 0.4701 - precision: 0.7806 - val_loss: 0.3307 - val_mse: 0.0821
- val_recall: 0.4444 - val_precision: 0.6774
Epoch 65/100
0.0730 - recall: 0.4651 - precision: 0.7888 - val_loss: 0.3302 - val_mse: 0.0821
- val_recall: 0.4286 - val_precision: 0.6750
Epoch 66/100
0.0728 - recall: 0.4701 - precision: 0.8009 - val_loss: 0.3330 - val_mse: 0.0824
- val_recall: 0.4286 - val_precision: 0.6694
Epoch 67/100
0.0727 - recall: 0.4765 - precision: 0.7669 - val_loss: 0.3278 - val_mse: 0.0817
- val_recall: 0.4392 - val_precision: 0.6748
Epoch 68/100
0.0737 - recall: 0.4714 - precision: 0.7541 - val_loss: 0.3296 - val_mse: 0.0826
- val_recall: 0.4233 - val_precision: 0.6723
Epoch 69/100
0.0724 - recall: 0.4727 - precision: 0.7949 - val_loss: 0.3292 - val_mse: 0.0822
- val_recall: 0.4127 - val_precision: 0.6555
Epoch 70/100
0.0737 - recall: 0.4765 - precision: 0.7812 - val_loss: 0.3271 - val_mse: 0.0821
- val recall: 0.4074 - val precision: 0.6638
Epoch 71/100
0.0717 - recall: 0.4917 - precision: 0.8096 - val_loss: 0.3311 - val_mse: 0.0822
- val_recall: 0.4180 - val_precision: 0.6695
Epoch 72/100
0.0726 - recall: 0.4727 - precision: 0.7782 - val_loss: 0.3296 - val_mse: 0.0816
- val_recall: 0.4339 - val_precision: 0.6613
Epoch 73/100
0.0717 - recall: 0.4956 - precision: 0.7943 - val_loss: 0.3293 - val_mse: 0.0812
- val_recall: 0.4497 - val_precision: 0.6746
Epoch 74/100
```

```
0.0726 - recall: 0.4867 - precision: 0.7897 - val_loss: 0.3343 - val_mse: 0.0823
- val_recall: 0.4392 - val_precision: 0.6535
Epoch 75/100
0.0716 - recall: 0.4803 - precision: 0.7875 - val_loss: 0.3298 - val_mse: 0.0817
- val_recall: 0.4074 - val_precision: 0.6754
Epoch 76/100
0.0715 - recall: 0.4790 - precision: 0.8038 - val_loss: 0.3348 - val_mse: 0.0818
- val_recall: 0.4444 - val_precision: 0.6720
Epoch 77/100
0.0712 - recall: 0.5070 - precision: 0.7917 - val_loss: 0.3285 - val_mse: 0.0806
- val_recall: 0.4603 - val_precision: 0.6850
Epoch 78/100
0.0714 - recall: 0.4790 - precision: 0.7725 - val_loss: 0.3296 - val_mse: 0.0812
- val_recall: 0.4444 - val_precision: 0.6774
Epoch 79/100
0.0698 - recall: 0.5006 - precision: 0.8024 - val_loss: 0.3295 - val_mse: 0.0812
- val_recall: 0.4392 - val_precision: 0.6803
Epoch 80/100
0.0697 - recall: 0.5019 - precision: 0.7869 - val_loss: 0.3334 - val_mse: 0.0816
- val_recall: 0.4550 - val_precision: 0.6772
Epoch 81/100
0.0708 - recall: 0.4867 - precision: 0.7913 - val_loss: 0.3292 - val_mse: 0.0807
- val_recall: 0.4497 - val_precision: 0.6641
Epoch 82/100
0.0699 - recall: 0.4943 - precision: 0.8071 - val_loss: 0.3373 - val_mse: 0.0818
- val recall: 0.4921 - val precision: 0.6643
Epoch 83/100
0.0701 - recall: 0.4981 - precision: 0.7809 - val_loss: 0.3388 - val_mse: 0.0827
- val_recall: 0.4709 - val_precision: 0.6593
Epoch 84/100
0.0717 - recall: 0.5019 - precision: 0.7853 - val_loss: 0.3316 - val_mse: 0.0818
- val_recall: 0.4550 - val_precision: 0.6565
Epoch 85/100
0.0708 - recall: 0.4917 - precision: 0.7787 - val_loss: 0.3424 - val_mse: 0.0824
- val_recall: 0.4444 - val_precision: 0.6512
Epoch 86/100
```

```
0.0702 - recall: 0.4994 - precision: 0.7892 - val_loss: 0.3376 - val_mse: 0.0823
- val_recall: 0.4233 - val_precision: 0.6612
Epoch 87/100
0.0703 - recall: 0.5032 - precision: 0.7920 - val_loss: 0.3399 - val_mse: 0.0827
- val_recall: 0.4709 - val_precision: 0.6544
Epoch 88/100
0.0694 - recall: 0.4981 - precision: 0.7824 - val_loss: 0.3406 - val_mse: 0.0820
- val_recall: 0.4444 - val_precision: 0.6614
Epoch 89/100
0.0695 - recall: 0.5146 - precision: 0.7879 - val_loss: 0.3379 - val_mse: 0.0819
- val_recall: 0.4339 - val_precision: 0.6667
Epoch 90/100
0.0699 - recall: 0.5044 - precision: 0.7846 - val_loss: 0.3369 - val_mse: 0.0816
- val_recall: 0.4444 - val_precision: 0.6614
Epoch 91/100
0.0703 - recall: 0.5044 - precision: 0.7846 - val_loss: 0.3421 - val_mse: 0.0821
- val_recall: 0.4550 - val_precision: 0.6719
Epoch 92/100
0.0694 - recall: 0.5159 - precision: 0.8024 - val_loss: 0.3424 - val_mse: 0.0819
- val_recall: 0.4127 - val_precision: 0.6783
Epoch 93/100
0.0696 - recall: 0.5057 - precision: 0.7960 - val_loss: 0.3389 - val_mse: 0.0811
- val_recall: 0.4497 - val_precision: 0.6800
Epoch 94/100
0.0693 - recall: 0.4930 - precision: 0.7951 - val_loss: 0.3394 - val_mse: 0.0814
- val recall: 0.4550 - val precision: 0.6615
Epoch 95/100
0.0688 - recall: 0.5032 - precision: 0.7984 - val_loss: 0.3383 - val_mse: 0.0813
- val_recall: 0.4339 - val_precision: 0.6891
Epoch 96/100
0.0683 - recall: 0.5044 - precision: 0.8135 - val_loss: 0.3393 - val_mse: 0.0813
- val_recall: 0.4444 - val_precision: 0.6614
Epoch 97/100
0.0662 - recall: 0.5146 - precision: 0.8198 - val_loss: 0.3460 - val_mse: 0.0819
- val_recall: 0.4392 - val_precision: 0.6535
Epoch 98/100
```

```
0.0685 - recall: 0.5032 - precision: 0.7936 - val_loss: 0.3435 - val_mse: 0.0814
    - val_recall: 0.4603 - val_precision: 0.6744
    Epoch 99/100
    0.0682 - recall: 0.5108 - precision: 0.7976 - val_loss: 0.3462 - val_mse: 0.0817
    - val_recall: 0.4603 - val_precision: 0.6641
    Epoch 100/100
    0.0683 - recall: 0.5133 - precision: 0.8000 - val_loss: 0.3453 - val_mse: 0.0817
    - val_recall: 0.4339 - val_precision: 0.6508
[23]: <keras.callbacks.History at 0x2e611cb1e20>
[30]: from sklearn.metrics import classification_report
     # Obtener las predicciones del modelo DNN
     y_pred = dnn.predict(X_test_scaled_pca)
     y_pred = [1 if y>=0.5 else 0 for y in y_pred]
     # Obtener el informe de clasificación
     dnn_report = classification_report(y_test, y_pred, output_dict=True)
     # Obtener el recall ponderado del clasificador XGBoost
     dnn_weighted_recall = dnn_report['weighted avg']['recall']
     dnn_weighted_precision = dnn_report['weighted avg']['precision']
     # Obtener las predicciones del modelo para MSE:
     y_train_pred = dnn.predict(X_train_scaled_pca)
     y_train_pred = [1 if y>=0.5 else 0 for y in y_train_pred]
     # Evaluar el modelo DNN y obtener las métricas
     dnn_mse = dnn.evaluate(X_test_scaled_pca, y_test)[1]
     dnn_train_mse = mean_squared_error(y_train, y_train_pred)
     dnn_test_mse = mean_squared_error(y_test, y_pred)
     # Crear un diccionario de métricas para DNN:
     dnn_metrics_dict = {'recall': dnn_weighted_recall,
                     'precision': dnn_weighted_precision,
                     'cv_mse': dnn_mse,
                     'train_mse':dnn_train_mse,
                     'test_mse': dnn_test_mse}
     dnn_metrics_dict
    94/94 [=======] - 0s 2ms/step
    218/218 [========= ] - Os 2ms/step
    0.0841 - recall: 0.4163 - precision: 0.7250
```

```
[30]: {'recall': 0.8962516733601071,
     'precision': 0.8851589521599256,
     'cv mse': 0.08408176898956299,
     'train_mse': 0.08537810302769408,
     'test_mse': 0.1037483266398929}
   Red neuronal convolucional unidimensional (CNN)
[26]: from keras.layers import Conv1D, Flatten, Reshape
    from keras.callbacks import EarlyStopping
[27]: # Crear la red neuronal convolucional unidimensional:
    cnn = Sequential()
    cnn.add(Reshape((X_train_scaled_pca.shape[1], 1),__
     →input_shape=(X_train_scaled_pca.shape[1],)))
    cnn.add(Conv1D(32, 3, activation='relu'))
    cnn.add(Dropout(0.25))
    cnn.add(Flatten())
    cnn.add(Dense(32, activation='relu'))
    #cnn.add(Dense(16, activation='relu'))
    cnn.add(Dense(1, activation='sigmoid'))
    # Compilar el modelo
    cnn.compile(loss='binary_crossentropy',
             optimizer='sgd',
             metrics=['mse'])
    # Entrenar la red neuronal
    cnn.fit(X_train_scaled_pca, y_train, epochs=100, batch_size=32,__
     →validation_split=0.2, verbose=1)
   Epoch 1/100
   0.1399 - val_loss: 0.3569 - val_mse: 0.1030
   Epoch 2/100
   0.0989 - val_loss: 0.3342 - val_mse: 0.0968
   Epoch 3/100
   0.0940 - val_loss: 0.3209 - val_mse: 0.0927
   Epoch 4/100
   0.0898 - val_loss: 0.3189 - val_mse: 0.0922
   Epoch 5/100
   0.0884 - val_loss: 0.3161 - val_mse: 0.0895
   Epoch 6/100
```

```
0.0874 - val_loss: 0.3170 - val_mse: 0.0898
Epoch 7/100
0.0867 - val_loss: 0.3088 - val_mse: 0.0873
Epoch 8/100
0.0855 - val_loss: 0.3081 - val_mse: 0.0853
Epoch 9/100
0.0849 - val_loss: 0.3084 - val_mse: 0.0859
Epoch 10/100
0.0841 - val_loss: 0.3062 - val_mse: 0.0850
Epoch 11/100
0.0834 - val_loss: 0.3070 - val_mse: 0.0851
Epoch 12/100
0.0832 - val_loss: 0.3058 - val_mse: 0.0852
Epoch 13/100
0.0828 - val_loss: 0.3047 - val_mse: 0.0832
Epoch 14/100
0.0811 - val_loss: 0.3047 - val_mse: 0.0839
Epoch 15/100
0.0817 - val_loss: 0.3073 - val_mse: 0.0830
Epoch 16/100
0.0812 - val_loss: 0.3054 - val_mse: 0.0832
Epoch 17/100
0.0808 - val_loss: 0.3041 - val_mse: 0.0824
Epoch 18/100
0.0801 - val loss: 0.3025 - val mse: 0.0823
Epoch 19/100
0.0800 - val_loss: 0.3037 - val_mse: 0.0821
Epoch 20/100
0.0794 - val_loss: 0.3012 - val_mse: 0.0818
Epoch 21/100
0.0800 - val_loss: 0.3010 - val_mse: 0.0819
Epoch 22/100
```

```
0.0793 - val_loss: 0.3036 - val_mse: 0.0831
Epoch 23/100
0.0795 - val_loss: 0.3024 - val_mse: 0.0815
Epoch 24/100
0.0789 - val_loss: 0.3055 - val_mse: 0.0814
Epoch 25/100
0.0785 - val_loss: 0.3070 - val_mse: 0.0813
Epoch 26/100
0.0784 - val_loss: 0.3019 - val_mse: 0.0810
Epoch 27/100
0.0774 - val_loss: 0.3019 - val_mse: 0.0807
Epoch 28/100
0.0790 - val_loss: 0.3025 - val_mse: 0.0814
Epoch 29/100
0.0778 - val_loss: 0.3037 - val_mse: 0.0809
Epoch 30/100
0.0764 - val_loss: 0.3036 - val_mse: 0.0824
Epoch 31/100
0.0774 - val_loss: 0.3021 - val_mse: 0.0810
Epoch 32/100
0.0753 - val_loss: 0.3021 - val_mse: 0.0807
Epoch 33/100
0.0771 - val_loss: 0.3083 - val_mse: 0.0817
Epoch 34/100
0.0764 - val loss: 0.3050 - val mse: 0.0805
Epoch 35/100
0.0756 - val_loss: 0.3034 - val_mse: 0.0811
Epoch 36/100
0.0744 - val_loss: 0.3030 - val_mse: 0.0812
Epoch 37/100
0.0754 - val_loss: 0.3011 - val_mse: 0.0805
Epoch 38/100
```

```
0.0751 - val_loss: 0.3059 - val_mse: 0.0809
Epoch 39/100
0.0750 - val_loss: 0.3033 - val_mse: 0.0806
Epoch 40/100
0.0747 - val_loss: 0.3031 - val_mse: 0.0805
Epoch 41/100
0.0745 - val_loss: 0.3111 - val_mse: 0.0811
Epoch 42/100
0.0742 - val_loss: 0.3062 - val_mse: 0.0817
Epoch 43/100
0.0740 - val_loss: 0.3050 - val_mse: 0.0804
Epoch 44/100
0.0747 - val_loss: 0.3064 - val_mse: 0.0809
Epoch 45/100
0.0729 - val_loss: 0.3164 - val_mse: 0.0809
Epoch 46/100
0.0736 - val_loss: 0.3054 - val_mse: 0.0806
Epoch 47/100
0.0730 - val_loss: 0.3082 - val_mse: 0.0813
0.0732 - val_loss: 0.3080 - val_mse: 0.0804
Epoch 49/100
0.0730 - val_loss: 0.3042 - val_mse: 0.0806
Epoch 50/100
0.0729 - val loss: 0.3034 - val mse: 0.0805
Epoch 51/100
0.0732 - val_loss: 0.3072 - val_mse: 0.0803
Epoch 52/100
0.0729 - val_loss: 0.3119 - val_mse: 0.0809
Epoch 53/100
0.0722 - val_loss: 0.3119 - val_mse: 0.0806
Epoch 54/100
```

```
0.0724 - val_loss: 0.3096 - val_mse: 0.0807
Epoch 55/100
0.0724 - val_loss: 0.3104 - val_mse: 0.0819
Epoch 56/100
0.0728 - val_loss: 0.3136 - val_mse: 0.0810
Epoch 57/100
0.0720 - val_loss: 0.3104 - val_mse: 0.0808
Epoch 58/100
0.0714 - val_loss: 0.3091 - val_mse: 0.0816
Epoch 59/100
0.0716 - val_loss: 0.3049 - val_mse: 0.0799
Epoch 60/100
0.0722 - val_loss: 0.3066 - val_mse: 0.0803
Epoch 61/100
0.0708 - val_loss: 0.3123 - val_mse: 0.0801
Epoch 62/100
0.0710 - val_loss: 0.3098 - val_mse: 0.0811
Epoch 63/100
0.0705 - val_loss: 0.3110 - val_mse: 0.0812
0.0712 - val_loss: 0.3093 - val_mse: 0.0807
Epoch 65/100
0.0705 - val_loss: 0.3174 - val_mse: 0.0820
Epoch 66/100
0.0700 - val_loss: 0.3143 - val_mse: 0.0821
Epoch 67/100
0.0701 - val_loss: 0.3139 - val_mse: 0.0806
Epoch 68/100
0.0705 - val_loss: 0.3195 - val_mse: 0.0809
Epoch 69/100
0.0699 - val_loss: 0.3120 - val_mse: 0.0806
Epoch 70/100
```

```
0.0703 - val_loss: 0.3109 - val_mse: 0.0804
Epoch 71/100
0.0691 - val_loss: 0.3083 - val_mse: 0.0803
Epoch 72/100
0.0700 - val_loss: 0.3126 - val_mse: 0.0810
Epoch 73/100
0.0695 - val_loss: 0.3212 - val_mse: 0.0811
Epoch 74/100
0.0694 - val_loss: 0.3161 - val_mse: 0.0810
Epoch 75/100
0.0689 - val_loss: 0.3131 - val_mse: 0.0806
Epoch 76/100
0.0692 - val_loss: 0.3201 - val_mse: 0.0811
Epoch 77/100
0.0679 - val_loss: 0.3234 - val_mse: 0.0805
Epoch 78/100
0.0679 - val_loss: 0.3273 - val_mse: 0.0810
Epoch 79/100
0.0681 - val_loss: 0.3210 - val_mse: 0.0806
0.0679 - val_loss: 0.3209 - val_mse: 0.0806
Epoch 81/100
0.0676 - val_loss: 0.3243 - val_mse: 0.0806
Epoch 82/100
0.0678 - val loss: 0.3352 - val mse: 0.0812
Epoch 83/100
0.0673 - val_loss: 0.3304 - val_mse: 0.0816
Epoch 84/100
0.0683 - val_loss: 0.3334 - val_mse: 0.0803
Epoch 85/100
0.0676 - val_loss: 0.3276 - val_mse: 0.0810
Epoch 86/100
```

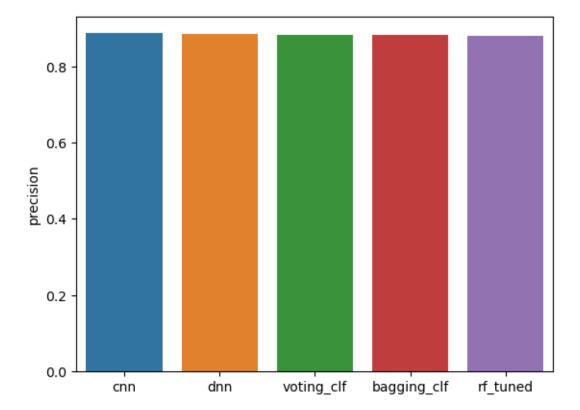
```
0.0672 - val_loss: 0.3297 - val_mse: 0.0805
Epoch 87/100
0.0660 - val_loss: 0.3287 - val_mse: 0.0803
Epoch 88/100
0.0663 - val_loss: 0.3279 - val_mse: 0.0815
Epoch 89/100
0.0658 - val_loss: 0.3258 - val_mse: 0.0807
Epoch 90/100
0.0662 - val_loss: 0.3299 - val_mse: 0.0809
Epoch 91/100
0.0672 - val_loss: 0.3259 - val_mse: 0.0805
Epoch 92/100
0.0668 - val_loss: 0.3277 - val_mse: 0.0800
Epoch 93/100
0.0665 - val_loss: 0.3379 - val_mse: 0.0814
Epoch 94/100
0.0667 - val_loss: 0.3353 - val_mse: 0.0811
Epoch 95/100
0.0650 - val_loss: 0.3312 - val_mse: 0.0802
0.0655 - val_loss: 0.3331 - val_mse: 0.0803
Epoch 97/100
0.0666 - val_loss: 0.3363 - val_mse: 0.0805
Epoch 98/100
0.0654 - val_loss: 0.3297 - val_mse: 0.0807
Epoch 99/100
0.0650 - val_loss: 0.3339 - val_mse: 0.0808
Epoch 100/100
0.0646 - val_loss: 0.3344 - val_mse: 0.0794
```

[27]: <keras.callbacks.History at 0x2e6150032b0>

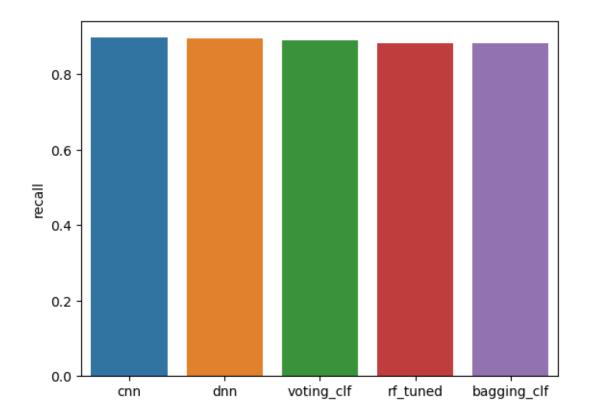
```
[31]: # Obtener las predicciones del modelo CNN
     y_pred = cnn.predict(X_test_scaled_pca)
     y_pred = [1 if y>=0.5 else 0 for y in y_pred]
     # Obtener el informe de clasificación
     cnn_report = classification_report(y_test, y_pred, output_dict=True)
     # Obtener el recall ponderado del clasificador XGBoost
     cnn_weighted_recall = cnn_report['weighted avg']['recall']
     cnn_weighted_precision = cnn_report['weighted avg']['precision']
     # Obtener las predicciones del modelo para MSE:
     y_train_pred = cnn.predict(X_train_scaled_pca)
     y_train_pred = [1 if y>=0.5 else 0 for y in y_train_pred]
     # Evaluar el modelo CNN y obtener las métricas
     cnn_mse = cnn.evaluate(X_test_scaled_pca, y_test)[1]
     cnn_train_mse = mean_squared_error(y_train, y_train_pred)
     cnn_test_mse = mean_squared_error(y_test, y_pred)
     # Crear un diccionario de métricas para CNN:
     cnn_metrics_dict = {'recall': cnn_weighted_recall,
                        'precision': cnn_weighted_precision,
                        'cv mse': cnn mse,
                        'train_mse':cnn_train_mse,
                        'test mse': cnn test mse}
     cnn_metrics_dict
     94/94 [=======] - Os 2ms/step
     218/218 [==========] - Os 2ms/step
     0.0812
[31]: {'recall': 0.8972556894243642,
      'precision': 0.8867924816139566,
      'cv mse': 0.08122765272855759,
      'train_mse': 0.07978189123260152,
      'test mse': 0.10274431057563588}
     Finalmente, comparamos en conjunto los modelos de mayor complejidad creados.
[33]: # Crear un DataFrame de modelos complejos:
     complex_models_df = pd.DataFrame([rf_tuned_metrics, voting_clf_metrics,_u
      ⇒bagging_clf_metrics,
                                     dnn_metrics_dict, cnn_metrics_dict],
                                     index=['rf_tuned', 'voting_clf', __
      ⇔'bagging_clf', 'dnn', 'cnn'])
     complex_models_df
```

```
[33]:
                    recall precision
                                                train_mse
                                                           test_mse
                                        cv_mse
                                                           0.116466
     rf_tuned
                  0.883534
                             0.880612 0.118238
                                                 0.098436
     voting_clf
                  0.889558
                             0.881465 0.106759
                                                 0.075908
                                                           0.110442
     bagging_clf
                  0.882865
                             0.881368 0.120822
                                                 0.102167
                                                           0.117135
     dnn
                  0.896252
                             0.885159
                                      0.084082
                                                 0.085378
                                                           0.103748
     cnn
                  0.897256
                             0.886792 0.081228
                                                 0.079782
                                                           0.102744
```

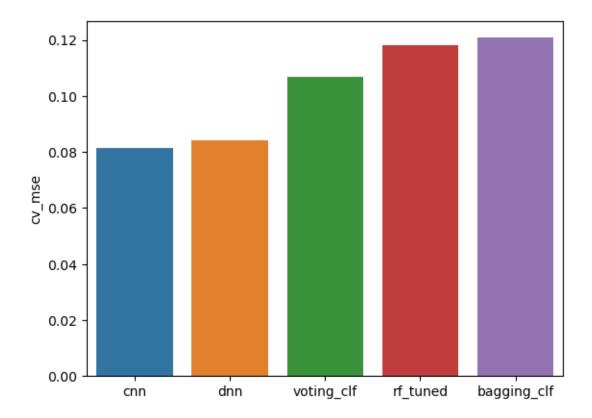
[34]: # Ranqueo de la precisión, de mejor a peor:
sorted_index = complex_models_df['precision'].sort_values(ascending=False).index
sns.barplot(x=complex_models_df.index, y='precision', data=complex_models_df,_u
order=sorted_index)
plt.show()



```
[35]: # Ranqueo del Recall, de mejor a peor:
sorted_index = complex_models_df['recall'].sort_values(ascending=False).index
sns.barplot(x=complex_models_df.index, y='recall', data=complex_models_df,_u
order=sorted_index)
plt.show()
```



[36]: # Ranqueo del MSE de la validación cruzada, de mejor a peor:
sorted_index = complex_models_df['cv_mse'].sort_values(ascending=True).index
sns.barplot(x=complex_models_df.index, y='cv_mse', data=complex_models_df,_u
order=sorted_index)
plt.show()



Conclusión: Dentro del conjunto de modelos complejos, las redes neuronales entrenadas presentan mejor desempeño tanto en Precisión como en Recall, especialmente el modelo CNN. También tienen mejor capacidad de generalización, interpretada como la diferencia del MSE sobre el conjunto de entrenamiento y el de evaluación.